

SAE DATA 

Mobilité Urbaine, Algorithmes & Éthique de l'IA

Objectif : Transformer des données brutes de vélos en libre-service en outils d'aide à la décision éthiques et performants.

Villes suggérées :

- **Paris** (Volume massif)
- **Saint-Pierre** (Topographie & Climat tropical)
- **Oslo** (Historique complet & saisonnalité marquée)

Référentiel de Compétences - DATA

Traiter des données massives à l'aide des techniques d'intelligence artificielle

- **Ingénierie & Qualité** : Appliquer les méthodologies adaptées de stockage, nettoyage et transformation.
- **Aide à la Décision** : Extraire des informations stratégiques
- **Communication** : Présenter les informations de manière adaptée aux publics visés (directions, clients, collaborateurs).
- **Éthique & Droit** : Intégrer les problématiques de sûreté, de respect de la vie privée et du droit d'auteur.
- **IA Responsable** : Mesurer et réduire l'impact environnemental des modèles d'IA.
- **Expertise** : Assurer une veille scientifique et technologique permanente pour garantir l'état de l'art.

Choix des "Packages"

Chaque groupe, binôme, se voit attribuer un **Package thématique**.

Un package est constitué de 3 piliers :

1. **La Problématique Métier** : Un défi concret (logistique, météo, vol, etc.) à résoudre pour l'exploitant.
2. **L'Algorithme Cible** : Un modèle spécifique à approfondir (théorie + pratique).
3. **L'Enjeu Éthique IA** : Une réflexion critique sur l'usage de l'IA dans ce contexte précis.

Package 1 : Logistique & Disponibilité (G1 & G2)

Problématique : Éviter la rupture de service

- **Objectif** : Prédire si une station aura moins de 3 vélos à $T + 60$ min.
- **Algorithmes** : **Random Forest** (G1) vs **XGBoost** (G2).

Éthique IA : La Boucle de Rétroaction

- Si l'IA prédit qu'une station sera vide et qu'on y remet des vélos, on renforce artificiellement son usage. Comment évaluer un modèle qui modifie le comportement du système en temps réel ?

Package 2 : Météo-Résilience (G3)

Problématique : Impact des aléas climatiques

- **Objectif** : Quantifier l'impact de la pluie, du vent et des températures sur la demande globale.
- **Algorithme** : Régression Linéaire Multiple.

Éthique IA : IA Verte vs IA Énergivore

- Le vélo est une énergie propre, mais l'entraînement de modèles IA consomme des ressources. Comment justifier le coût carbone de l'IA par rapport au gain d'efficacité du service ?

Package 3 : Cycles et Flux Temporels (G4 & G5)

Problématique : Le pouls de la ville

- **Objectif** : Identifier les rythmes (pendulaires, loisirs, événements) et prédire les volumes quotidiens/annuels.
- **Algorithme** : Séries Temporelles (ARIMA / SARIMA).

Éthique IA : Interprétabilité & Boîte Noire

- Si une IA décide de tarifier plus cher lors d'un pic prédit, comment l'expliquer à l'utilisateur ? Peut-on sacrifier la transparence au profit de la précision ?

Package 4 : Topographie et Effort (G6)

Problématique : L'influence du relief

- **Objectif** : Analyser comment la pente influence la prise et le dépôt des vélos (effet ventouse des bas de collines).
- **Algorithme** : SVM (Support Vector Machine).

Éthique IA : Biais et Exclusion Territoriale

- Si l'IA "apprend" que les zones en pente sont moins rentables, elle risque de suggérer de supprimer des stations. Comment l'algorithme peut-il corriger les inégalités d'accès au lieu de les renforcer ?

Package 5 : Vol, Disparition et Risques (G7)

Problématique : Sécuriser la flotte

- **Objectif** : Identifier les trajets à haut risque de vol ou de non-retour (abandon hors station).
- **Algorithme** : Random Forest (Classification).

Éthique IA : Profilage et Faux Positifs

- Quelles conséquences si l'IA classe à tort un usager comme "voleur" ? Risque de discrimination géographique (stigmatisation de certains quartiers) et droit à l'erreur humaine.

Package 6 : Clustering d'Usages (G8)

Problématique : Typologie des utilisateurs

- **Objectif** : Segmenter les usagers sans données nominatives (Vélotafeurs, touristes, noctambules).
- **Algorithme** : K-Means Clustering.

Éthique IA : Désanonymisation et Vie Privée

- Protection des données : même "anonymisée", une trace GPS peut révéler l'identité (domicile/travail). Où s'arrête l'analyse et où commence la surveillance ?

Liste des Livrables

1. Présentation: Enjeux Éthiques & IA

Chaque groupe présentera, en amont des travaux techniques, une analyse de **5 minutes** sur le sujet éthique lié à son package.

- **Contenu** : Analyse du risque (biais, vie privée, responsabilité), état de l'art législatif (RGPD, IA Act) et propositions de "mitigation" (comment limiter le risque par la technique).

2. Analyse Exploratoire & Fouille de Données (EDA)

Format: Jupyter Notebook + rapport des analyses et conclusions.

Avant toute modélisation, compréhension du jeu de données :

- **Analyse Univariée & Distributions** : Identification des lois de distribution des variables clés (durée de trajet, fréquentation par station). Traitement des données aberrantes (outliers).
- **Tests Statistiques** : Mise en œuvre de tests pour valider des hypothèses.
- **Réduction de Dimension (ACP)** : Analyse en Composantes Principales pour identifier les corrélations entre variables et isoler les facteurs expliquant la plus grande variance.
- **Clustering exploratoire** : Utilisation de méthodes non supervisées pour segmenter les stations ou les comportements d'usage avant la phase de prédiction.

3. Architecture des Données

Format: rapport technique.

- **Schéma Entité-Relation (ERD)** : Modélisation conceptuelle montrant les entités (Stations, Trajets, Météo, Vélos) et leurs cardinalités.
- **Schéma Relationnel (Modèle Conceptuel de Données)** : Fournir le diagramme des tables (Stations, Trajets, Météo, vélos) avec les clés primaires/étrangères.

4. Présentation 2: Fonctionnement de l'Algorithme

5 minutes : Explications du fonctionnement de l'outil imposé dans votre package (ex: Comment XGBoost itère sur les erreurs ? Comment ARIMA gère la saisonnalité ?). L'objectif est de faire comprendre le concept mathématique à vos camarades.

5. Visualisation : Interface Utilisateur (UI)

- **Dashboard Décisionnel** : Création d'une interface permettant de visualiser l'état du réseau.
- **Indicateurs Temps Réel** : Affichage des prédictions générées par vos algorithmes (ex: scores de disponibilité, alertes "stock critique").

6. Rapport Technique & Méthodologie

- **Pipeline de traitement** : Description des étapes de nettoyage et de préparation des données.
- **Validation du modèle** :
 - Calcul des performances, selon sujet (MAE, RMSE, F1-Score, Matrice de confusion).
 - **Méthode de validation** : Utilisation de la *Cross-Validation* (ou *Time-Series Split*) pour garantir la robustesse.
 - **Prévention du surapprentissage (Overfitting)** : Justification des techniques employées pour assurer que le modèle reste reproductible sur de nouvelles données.

7. Soutenance Finale

Chaque groupe dispose de **10 minutes** de présentation suivies de **5 minutes** de questions/réponses.

Structure attendue de la soutenance :

1. **Synthèse de la problématique** : Quel problème tentez-vous de résoudre ?
2. **Méthodologie de Fouille** : Qu'avez-vous découvertes lors de l'EDA ?
3. **Choix Techniques** : Justification de l'architecture de la base de données et de la configuration de l'algorithme.
4. **Démonstration de l'Outil** : Présentation de votre interface utilisateur et des indicateurs d'aide à la décision.
5. **Résultats & Validation** : Performance réelle du modèle et limites rencontrées.
6. **Conclusion Éthique** : Synthèse critique de l'usage de l'IA pour ce cas précis.

Points d'Attention (1/2)

1. Disponibilité des Données

- **N'attendez pas** : Testez vos flux d'API (temps réel) et téléchargez vos fichiers historiques dès que possible.
- **Vérification** : Réalisez un premier échantillonnage (extraits de données) pour confirmer que votre ville dispose des colonnes nécessaires à votre package (ex: géolocalisation, météo, ID vélos).
- L'EDA (Analyse Exploratoire) est votre boussole. Si les données sont trop bruitées ou incomplètes sur une ville, **changez de ville** avant la fin de la semaine 1.

Points d'Attention (2/2)

2. Stratégie de Stockage : Accumuler pour Prédire

- Pour les prédictions en temps réel, lancez un script de récupération (script de "scraping" ou stockage en DB) au plus vite afin de constituer votre propre historique d'entraînement.

3. Anticipation des Dépendances

- Vérifiez la compatibilité entre vos sources (ex: la station de météo est-elle assez proche des stations de vélos ?).
- Anticipez les pannes d'API ou les quotas de requêtes limités.

Rétro-planning (4 Semaines)

- **Semaine 1 : Immersion & Éthique.** Choix de la ville, récupération des données (API/CSV), réflexion éthique.
- **Présentation Ethique 15/04**
- **Semaine 2 : Exploration & Architecture.** Analyse exploratoire (EDA). Conception du schéma ERD. Recherches sur algorithme.
- **Présentation Algorithme 23/04**
- **Semaine 3 : Modélisation & UI.** Entraînement des modèles, validation croisée, développement du Dashboard.
- **Semaine 4 : Finalisation & Soutenance.** Rédaction du rapport technique
- **Soutenance Finale 06/05**